

Word-Counter:


다양한 문서 형식에서 단어 집계

분석 · 조회 · 저장 · 성능 개선

발표자: 박상호


발표일: 2026-10-01

처리 흐름



파일 읽기와 단어 토큰화를 분리하고, 파일별 집계 결과를 전체 결과로 합산

주요 클래스와 역할



기본 기능 시연

다양한 파일 형식의 단어 집계부터 결과 조회·저장, 오류 처리까지 확인

1

파일 분석

`samples/equivalent`

2

결과 조회

`news-1000.csv`

3

결과 저장

`out/counts.tsv`

4


오류 처리

`samples/invalid`

정상 파일의 결과는 유지하고, 실패 파일의 부분 집계는 제외

성능 개선: 문자 순회 기반 토큰나이저

정규식 기반 RegexTokenizer를 문자 단위로 순회하는 SimpleTokenizer로 변경



44%


27.3MB 파일 처리 시간 감소

43%

208MB 파일 처리 시간 감소

병렬 처리

스레드 풀에서 파일별 단어 빈도를 병렬 집계한 뒤, 집계 결과를 순차 합산



5.88배

208MB 파일 16스레드

큰 입력에서 더 높은 병렬 성능 향상 확인

- 파일 읽기와 토큰화 비용의 비중이 커져 병렬 효율 증가

스레드 수에 비례하는 성능 향상에는 도달하지 못함

- 스레드 풀 생성, 작업 제출·관리와 결과 합산에 따른 고정 비용

병렬 처리 시연

같은 16개 파일을 1스레드와 4 스레드로 분석하여 처리 시간과 결과 비교


입력	<code>data/local/perf-64/many</code>
처리방식	<code>FIXED_THREAD_POOL</code>
스레드 수	<code>MAX_THREAD_COUNT:</code> <code>1 → 4</code>

파일별 독립 집계로 병렬 처리하고, 성공한 결과만 순차 합산

DB 저장 방식 최적화

단어별 집계 결과를 메모리 대신 DB에 저장하고
저장 방식을 단계적으로 최적화

**SQL 왕복·커밋 횟수와 저장할 데이터 수를
줄여 처리 시간 단축**



체크포인트 저장과 중단 후 재개

파일별 집계 결과를 저장하고
재실행 시 유효한 체크포인트를 복원하여 중복 분석 방지

